

Image Generation Models: A Technical History

阅读报告

钟兴炜

chungxw@whu.edu.cn

武汉大学

2026 年 5 月 11 日

1 论文基本信息

论文标题	Image Generation Models: A Technical History
作者	Rouzbeh Shirvani (rouzbeh.asghari@gmail.com)
发表信息	arXiv: 2603.07455v2 [cs.CV], 2026 年 3 月 29 日
类型 / 篇幅	综述 (Survey), 55 页, 168 篇参考文献
所属领域	计算机视觉 · 深度学习 · 图像生成

2 内容概述

本文是一篇系统性的图像生成模型技术综述，按时间顺序梳理了过去十年从 VAE、GAN、Normalizing Flows、自回归/Transformer 模型到扩散模型、Flow Matching，以及视频生成和伪造检测的完整技术演进路径。全文共 10 章，各章要点如下：

- §1 引言：指出图像生成领域文献碎片化，缺乏跨模型族的统一技术性综述，明确综述目标与范围。
- §2 VAE：从 ELBO 推导与重参数化技巧出发，讨论 KL Collapse 与 β -VAE 解决方案，介绍 PixelVAE、条件 VAE (CVAE)、IWAE、DRAW、NVAE 等变体。VAE 优势在于可解释性与可控性，局限是模糊重建。
- §3 GAN：从 Goodfellow 原始 GAN 到 DCGAN、WGAN/WGAN-GP 的训练稳定性改进，涵盖条件 GAN (CGAN/AC-GAN)、StyleGAN v1-v3 的渐进式生成与风格解耦，StackGAN/AttnGAN 的文本到图像生成，以及 SRGAN 超分辨率应用。

- §4 **Normalizing Flows**: 基于变量替换公式与可逆映射, 详述 NICE、Real NVP 的仿射耦合、Glow 的 1×1 可逆卷积以及 MAF、IAF 等变体。优势在于精确似然与一步采样, 但在复杂高分辨率生成上落后于扩散模型。
- §5 **自回归与 Transformer**: 从 PixelRNN/PixelCNN 逐像素生成, 到 Image GPT 的自注意力替代卷积、VQ-VAE/VQ-GAN 的离散潜在空间、DALL-E 文本到图像、MaskGIT 并行解码、Muse 双尺度 tokenizer、Parti (20B 参数) 的缩放实验。
- §6 **扩散模型**: 从 Sohl-Dickstein 的热力学启发到 DDPM 噪声预测重参数化与 UNet 架构、DDIM 加速采样、条件扩散 (classifier / classifier-free guidance)、LDM/Stable Diffusion 的潜在空间操作、DiT 的 Transformer 骨干、DALL-E 2/Imagen/DALL-E 3/SDXL 等大规模系统。
- §7 **Rectified Flow 与 Flow Matching**: 基于连续 Normalizing Flow 的 ODE 框架。Rectified Flow 通过直线插值与 Reflow 实现少量步采样; Flow Matching 利用条件概率路径回归向量场, 在最优传输路径下以更少 NFE 达到更低 FID。
- §8 **视频生成**: 从 VGAN/MoCoGAN 的 GAN 方案, 到 VideoGPT 的 VQ-VAE + 自回归 Transformer, 再到视频扩散模型 (Imagen Video / Stable Video Diffusion / Lumiere / Make-A-Video)。
- §9 **伪造检测与社会影响**: 讨论 deepfake 危害、检测方法 (眨眼检测、频谱伪影、DIRE 扩散重建误差)、基准数据集 (FaceForensics++、DFDC)、水印技术 (Stable Signature, 48-bit 签名, 误检率 $1/10^9$)。
- §10 **总结**: 回顾各模型演进, 指出未来方向——更少步生成、时序与 3D 一致性、条件控制、水印与负责任部署。

3 主要贡献

1. **首次提供跨模型族的统一技术综述**。不同于仅聚焦单一模型族的综述, 本文覆盖 VAE、GAN、Flow、Autoregressive、Diffusion、Flow Matching 等所有主流生成模型, 对每种模型提供从数学公式到训练算法的完整技术 walkthrough。
2. **技术细节与训练流程并重**。对每种模型给出: (i) 底层目标函数与数学推导, (ii) 架构设计选择, (iii) 算法级训练步骤 (以伪代码 Box 形式呈现, 全文共 12 个), (iv) 常见失败模式与优化技巧。对工程实现具有直接参考价值。
3. **覆盖最新进展**。包含 2024–2026 年最新工作, 如 Rectified Flow/Flow Matching 驱动的现代生成系统、Stable Video Diffusion、Lumiere 等, 追踪了从扩散模型到 Flow-based 范式的技术转变。
4. **兼顾社会责任维度**。专设章节讨论 deepfake 检测、频率域伪影、水印技术等防御手段, 技术综述与社会影响并重, 在同类综述中较为少见。
5. **清晰的技术演进叙事**。按时间顺序组织, 帮助读者理解各模型为何出现、解决了什么问题、遗留了什么局限, 形成完整的认知框架。

4 各模型核心对比

表 1: 主流图像生成模型对比

模型族	训练方式	生成质量	采样速度	主要局限
VAE	ELBO 最大化	中等 (模糊)	一步 (快)	后验坍塌、模糊重建
GAN	对抗博弈	高 (清晰)	一步 (快)	模式坍塌、训练不稳定
Normalizing Flow	精确对数似然	中等	一步 (快)	维度受限、高分辨率困难
自回归/Transformer	最大似然	高	逐 token (慢)	$O(n^2)$ 注意力、顺序依赖
扩散模型 (DDPM)	噪声预测 MSE	很高	数百 ~ 千步 (慢)	采样步骤多、耗时长
Rectified Flow / FM	向量场回归 MSE	很高	少量步 (快)	边界条件敏感

5 值得关注的亮点

- 数学推导完整。** VAE 从 ELBO 到重参数化, GAN 从 min-max 到 WGAN 的 Wasserstein 距离, 扩散模型从马尔可夫链到 DDIM 的确定性采样——每个公式都有上下文解释, 适合作为教学参考资料。
- 算法步骤清晰。** 文中包含 12 个 Box, 以伪代码形式给出 CVAE、Normalizing Flow、DDPM、DALL-E 2、Rectified Flow、Flow Matching、Stable Video Diffusion 等模型的完整训练/推理流程, 可直接指导复现。
- 模型间联系被揭示。** 例如 VQ-VAE 是扩散模型进入潜在空间的关键使能技术; DDPM 的重参数化技巧 (预测噪声而非均值) 是其工程可行性的关键; Classifier-free guidance 从标签条件推广到文本条件直接催生了 GLIDE 和 Stable Diffusion。
- 范式转移信号被捕捉。** 论文敏锐地捕捉到从扩散模型到 Flow Matching 的转变趋势——Rectified Flow 和 Flow Matching 提供更干净的连续时间动态、更少的采样步数和更好的训练稳定性, 正成为下一代生成系统的基础。
- 安全性讨论务实。** 具体介绍了 DIRE (扩散重建误差检测)、频谱伪影分析 (上卷积引入的棋盘格频率特征)、Stable Signature 水印等技术方案, 而非泛泛而谈。

6 读后评价

优点

- 技术深度与广度平衡得当, 公式推导严谨但不过度晦涩, 适合作为入门到进阶的桥梁读物。
- 各章节 Conclusion 和末章 Final Conclusion 提供精炼总结, 可直接引用。
- 数学符号统一、Box 式训练流程可操作性强, 便于复现。
- 引用全面 (168 篇), 涵盖各方向关键论文。

不足

1. 几乎没有实验结果对比——综述未提供各模型在标准 benchmark 上的 FID/IS 等量化对比表，缺少定量比较是明显短板。
2. 各模型之间的内在理论联系讨论不够深入（如 score-based SDE 统一框架），更多是按时间线的并列叙述。
3. 实验架构多为文字描述，缺少架构图对直观理解有一定影响。
4. 对最新闭源商业模型（如 DALL-E 3、Sora 等）的技术细节披露有限。

对个人研究的启发

本文为红外图像超分辨率研究提供了清晰的模型选型参考——扩散/Flow Matching 模型在图像重建质量和多样性方面优于 GAN 和 VAE，Flow Matching 正成为更高效的选择；潜在空间操作和条件控制机制可直接借鉴用于红外 SR 的退化建模与重建。

钟兴炜 · chungxw@whu.edu.cn · 武汉大学

2026 年 5 月 11 日